

PREDICTION AND DETECTION OF EPILEPTIC SEIZURES

Jorge Melo & Xavier Pinho

Grupo 12 - PL2

2018/2019

Neuronal and Fuzzy Computation (MIEB)

1. Introdução

A epilepsia é uma doença neurológica caracterizada por crises epiléticas de duração e intensidade variável, estas crises tendem a ser recorrentes e a não ter uma causa subjacente definida. As crises epiléticas são o resultado de atividade excessiva e anormal das células nervosas do córtex cerebral. A epilepsia é frequentemente confirmada através de um eletroencefalograma (EEG). Afeta cerca de 1% da população mundial e não tem cura, embora portadores deste distúrbio consigam ter um quotidiano controlado através de medicação, desta forma é importante desenvolver soluções que possam prever e detetar estas convulsões.

O objetivo deste trabalho é, construir modelos capazes de detetar e/ou prever ataques epiléticos em pacientes através de uma aplicação. A partir de exames de EEG retiraram-se registos de 29 features que, após tratamento permitem distinguir classes que correspondem a diferentes estados do cérebro, nomeadamente: interictal (estado normal do cérebro), pré-ictal (fases que antecede um convulsão), ictal (convulsão) e pós-ictal (fase após a convulsão). A divisão destas classes permite assim a criação de padrões nas fases pré-ictal e ictal, que possibilitam a construção de Redes Neurais capazes de prever ou detetar convulsões.

Após a criação das Redes Neurais, estas foram avaliadas através de métricas comuns como especificidade, sensibilidade e matriz confusão.

2. Aplicação (GUIDE)

De forma a facilitar a utilização do programa por parte do utilizador, foi criada uma aplicação através do GUIDE, cujo design pode ser observado nas figura 1 - 4.

A aplicação é constituída por quatro Menus: Main, Train Shallow, Test Shallow, Train Deep, Test.

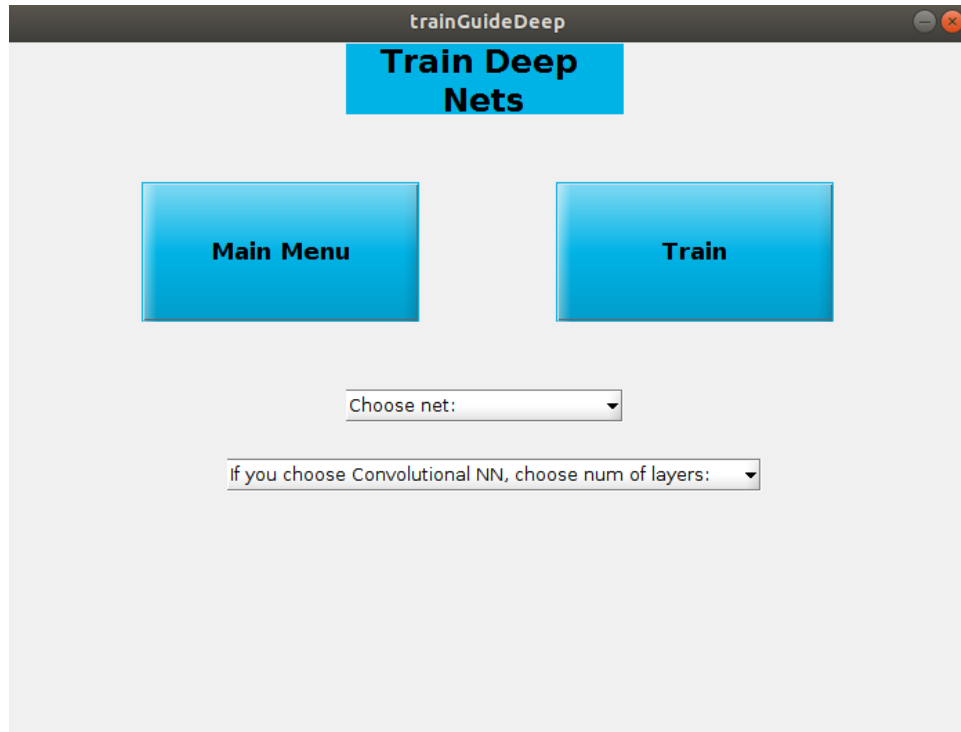


Figura 1 - Menu Deep Networks.

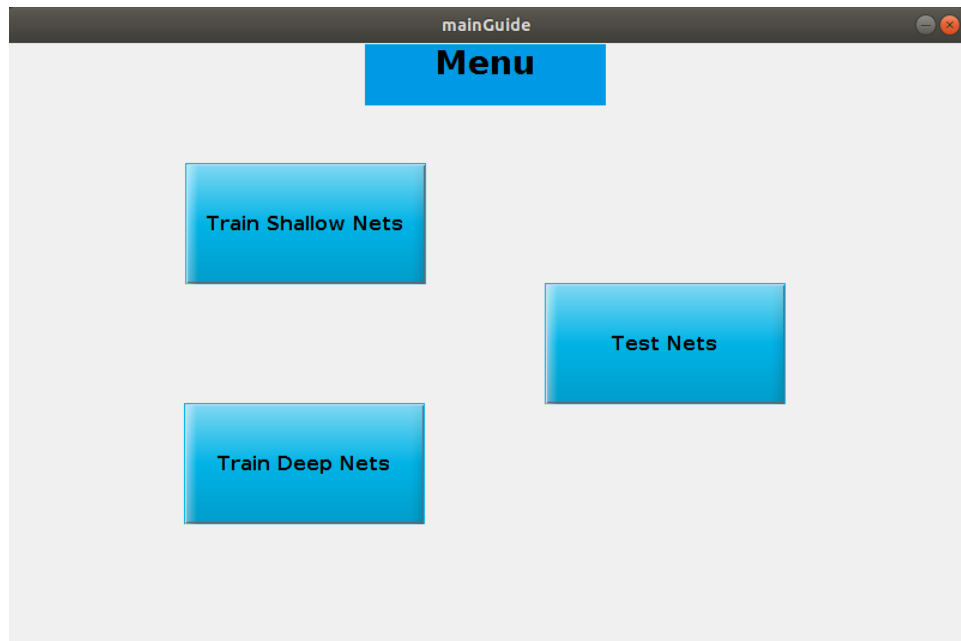


Figura 2 - Menu Principal.

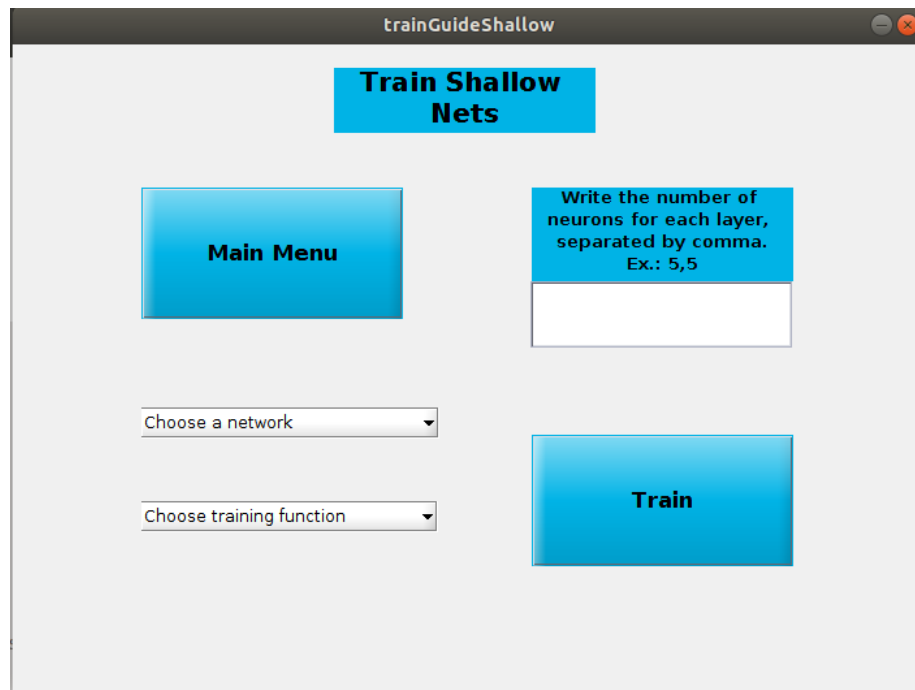


Figura 3 - Menu Train Shallow Networks.

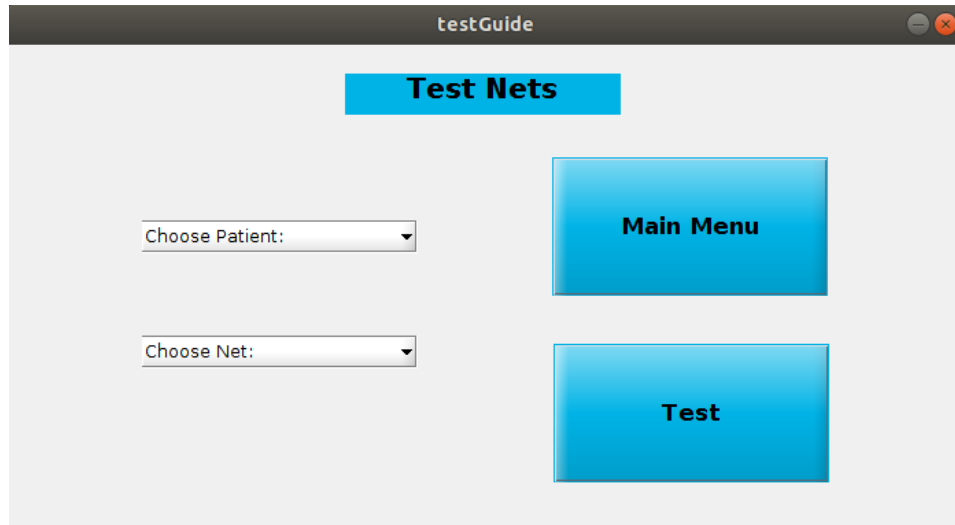


Figura 4 - Menu de teste.

3. Métodos

- **Pre-Processamento:**
 - ◆ **Shallow Networks**

Os dados iniciais estavam divididos em matriz das features e matriz target, para os dois pacientes.

Relativamente à matriz target, inicialmente apresentava exclusivamente 0s ou 1s, foi então necessário converter para as quatro classes já referidas anteriormente. Sabendo que 10min (600 valores) antes do primeiro 1 correspondem à fase pré-ictal e que 5min (300 valores) depois após o ultimo 1 correspondem à fase pós-ictal. Os pontos sobrantes foram classificados como interictal.

A matriz inicial de uma só coluna de 0s e 1s foi convertida para uma matriz de quatro colunas, onde: ictal - [0 0 1 0], pré-ictal - [0 1 0 0], pós-ictal - [0 0 1 0] e interictal - [1 0 0 0].

De forma a evitar um possível overfitting uma vez que a classe interictal predomina em relação a todas as outras, foi realizado um balanceamento das classes de forma a haver igualdade no número de pontos para as diferentes classes.

A mesma transformação foi aplicada à matriz das features através da correspondência de índices.

◆ Long Short-Term Memory

A matriz de features foi convertida para imagens de 29x29 e a matriz target para imagens de 29x4. Ficando assim com duas matrizes de 3 dimensões.

A matriz target foi convertida de numeric para categoric e apenas se consideraram duas classes, onde: [0 1 0 0] é 1 e tudo o resto é 0s.

Ambas as matrizes foram convertidas para estruturas do tipo cell.

Numa segunda abordagem a matriz de features foi convertida em cells de 29x600, onde se consideraram apenas o intervalo temporal imediatamente anterior ao estado pre-ictal, o estado pre-ictal e o momento posterior a este. O objetivo é ter uma cell com todo o período pre-ictal, de forma a dar uso das propriedades de uma rede LSTM na obtenção de conhecimento sobre esta fase.

A matriz target consiste num vetor categórico com valor 1 (pre-ictal) ou 0 (não pre-ictal) para cada célula.

◆ Convolutional Neural Network

A matriz de features construída para esta rede consiste em matrizes 29x29, ou seja, janelas de 29 segundos, contendo apenas pontos no mesmo estado (foram removidas as imagens que continham pontos em estados diferentes, p.e. pre-ictal e ictal). A matriz assume uma estrutura 4D, onde as 2 primeiras dimensões representam a largura e altura da imagem, a 3ª dimensão assume o valor 1 (imagem monocromática) e a 4ª dimensão representa o índice da imagem.

A matriz de targets consiste num vetor categórico que representa a fase em que se encontra cada imagem - 1 para pre-ictal e 0 para não pre-ictal.

- **Training Data-Set**

O data-set de treino é constituído pela junção dos dados de ambos pacientes, e a divisão em dados de treino e teste é feita na proporção de 80% para treino e 20% para teste.

- **Arquitetura das Redes Neurais**

- ◆ **Shallow-Networks**

Para construir os diferentes classificadores foram usadas duas diferentes arquiteturas: FeedForward e LayerRecurrent. Em ambas foram utilizadas diferentes combinações de funções de ativação, de treino, número de hidden layers e número de neurónios, de forma a encontrar o melhor classificador.

Tendo em conta a complexidade de algumas Redes Neurais é dada a possibilidade ao utilizador de utilizar recorrendo ao uso de Parallel e de GPU, de modo a acelerar o processo.

Uma vez que o objetivo do trabalho era prever e detetar ataques epilépticos, foi necessário distinguir as diferentes classes através da atribuição de diferentes pesos. As Shallow-Networks foram definidas para detetar enquanto que a Long Short-Term Memory e Convolution Network para prever seizures.

Toda as Redes Neurais foram obtidas através do MatLab e com o auxílio da toolbox Neural Network Toolbox.

- **Pós-Processamento**

O processo de pós-processamento teve por base o cálculo de métricas comuns como sensibilidade, precisão e especificidade em prever e detetar convulsões.

4. Resultados

De forma a avaliar a performance das diferentes Redes Neurais foram aplicados as métricas já referidos no pós-processamento.

Inicialmente, as Redes Neurais foram testadas com diferentes funções de treino: traingd, trainlm, trainscg, traingda e traingdm, das quais a que apresentava melhores resultados era a trainscg.

Em seguida, foram testadas diferentes funções de ativação: logsig entre as hidden layers e purelin entre a duas últimas camadas.

Foi ainda testado diferentes números de hidden layers: 100 - 50, 200 - 100, 400.

De forma a seleccionar as melhores Redes Neurais foram tidos em consideração valores de especificidade, precisão e sensibilidade, tanto para previsão como para detecção.

Os melhores resultados estão apresentados nas tabelas que se seguem, também foram geradas matrizes confusão para estes resultados (apenas visíveis na utilização da aplicação).

			Patient 54802			Patient 63502		
			Precisão	Sensibilidade	Especificidade	Precisão	Sensibilidade	Especificidade
FF	Scg	200/100	0.8601	0.0785	0.9316	0.8980	0.0380	0.9879
FF	Gd	200/100	0.9095	0.0091	0.9999	0.9034	0.1227	0.9994
FF	gda	200/100	0.5543	0.0040	0.9590	0.9034	0.0020	0.9983
FF	gdm	200/100	0.9113	0.0039	0.9998	0.9045	0.0000	0.9996
FF	lm	200/100	0.9113	0.0031	0.9996	0.9113	0.0031	0.9996
RR	Scg	200/100	0.9115	0	1	0.9049	0	1
RR	Gd	200/100	0.9115	0	1	0.9049	0	1
RR	gda	200/100	0.9115	0	1	0.9049	0	1
RR	gdm	200/100	0.8634	0.0781	0.8355	0.8935	0.0441	0.9813
RR	lm	200/100	-	-	-	-	-	-
FF	Scg	100/50	0.0092	0.0007	0.9936	0.0109	0	1
FF	Gd	100/50	0.2294	0.2049	0.6726	0.1817	0.1410	0.8310
FF	gda	100/50	0.0700	0.0456	0.7824	0.0359	0.0049	0.9604
FF	gdm	100/50	0.0092	0.009	1	0.0109	0	1
FF	Lm	100/50	-	-	-	-	-	-
RR	Scg	100/50	0.0092	0	1	0.0109	0	1
RR	Gd	100/50	0.9115	1	0	0.9049	1	0
RR	gda	100/50	0.0265	0	1	0.0281	0	1
RR	gdm	100/50	0.0528	0	1	0.0561	0	1
RR	lm	100/50	-	-	-	-	-	-
FF	Scg	400	0.3434	0.3422	0.3693	0.2355	0.2229	0.5224
FF	Gd	400	0.3172	0.3048	0.4922	0.1423	0.1013	0.7918
FF	gda	400	0.2149	0.2010	0.5037	0.0669	0.0406	0.8184

FF	gdm	400	0.2976	0.3009	0.2207	0.0932	0.0858	0.4016
FF	lm	400	-	-	-	-	-	-
RR	Scg	400	0.0265	0	1	0.0210	0	1
RR	Gd	400	0.0528	0	1	0.0561	0	1
RR	gda	400	0.9115	1	0	0.9049	0	1
RR	gdm	400	0.0265	0	1	0.0281	0	1
RR	lm	400	-	-	-	-	-	-
CN	-	1 layer	0.8087	0.1875	0.8322	0.9422	0.0746	0.9624
CN	-	2 layer	0.7718	0.3281	0.7887	0.9558	0.0448	0.9770
CN	-	3 layer	0.9275	0.1250	0.9579	0.9721	0	0.9948
LSTM		600 pts	0.6316	1	0.5	0.2727	0.3333	0.2500
LSTM		29 pts	0.8599	0.0477	0.9654	0.9343	0.0474	0.9741

Tabela 1 – Resultados para todas as Redes Neurais treinadas para ambos os pacientes. As Redes CN e LSTM destinam-se a *prever* e todas as outras para *detetar*.

Nota: Redes com função de treino LM exigem uma capacidade computacional elevada, o que impossibilitou a criação de algumas dessas redes.

5. Conclusões

Analisando os resultados da Tabela 1, facilmente se verifica que, em regra geral, todas as redes conseguem valores elevados de precisão e especificidade e valores reduzidos de sensibilidade.

Observando os resultados obtidos pode-se verificar que a Rede Neuronal melhor classifica do ponto de vista da previsão da ocorrência de seizures é a LSTM com janelas de 600 pontos, apresentando as métricas mais consistentes e a que melhor classifica do ponto de vista da deteção de seizures é a Feed Forward – Gradient Descend com [200 – 100] neurónios.

Dentro das Shallow Networks pode-se dizer que há uma correlação entre o número de camadas e os resultados, na medida em que a arquitetura que melhor se adequa ao problema é duas camadas [200-100] neurónios. Quando à função de treino que melhores resultados apresenta é a Scaled Gradient Descend.

Observa-se ainda que os testes no Paciente 54802 apresentam melhores resultados que no Paciente 63502, uma vez que o primeiro apresenta mais seizures.

No entanto, e como já era de certa forma esperado, nenhuma das Redes é totalmente viável quer na previsão quer na detecção de convulsões, isto deve-se maioritariamente à ausência de informação sobre as features utilizadas, impossibilitando saber quais destas são realmente significativas para o problema; outro ponto será o reduzido número de ocorrências de convulsões que os dados apresentavam (paciente 54802 - 31 seizures, paciente 63502 - 9 seizures). O facto do vetor target ser construído por nós através de uma estimativa sobre a duração (número de pontos) para a classe pré-ictal e pós-ictal também poderá ser uma das razões para as falhas nos nossos modelos, uma vez que esta estimativa pode não corresponder à realidade.

Na construção de Redes Neurais, tanto o tamanho como a divisão dos dados são relevantes factores para as suas performance e esta divisão foi feita com base em estimativas e tentativas.

Apesar da tentativa de melhorar a performance de todas as Redes Neurais, quer através de balanceamento, de atribuição de pesos a cada classe conforme a sua incidência e importância, diferentes combinações de arquiteturas e funções de treino, chega-se à conclusão que ainda é um enorme desafio prever e detetar convulsões através de Redes Neurais, o que deixa em aberto o tema a novas técnicas e abordagens, nomeadamente a utilização de Deep Networks que segundo o nosso trabalho apresenta resultados promissores.